ibimbing

Data Preparation untuk Analisis Churn Pengguna Spotify

Muhammad Rafiansyah Mahardika

Mini Project 1 - Data Science & Analyst
Bootcamp Offline Batch 1

24 Oktober 2025

Muhammad Rafiansyah Mahardika

Job Seeker

Education

S1 - Manajemen Bisinis Telekomunikasi dan Infromatika

Telkom University

Certification

- Certified Digital Marketing Specialists (2024)
- Certified Digital Marketing Specialists by BNSP (2024 - 2027)
- Intro to Data Analytics (2025)

Experience

- Marketing Communication
  at Euro Management Indonesia (Jul 2024 - Aug 2024)
- Chief Executive
  at Insight Telkom (Nov 2022 - Aug 2023)
- External Departement Staff
  at KMM Telkom University (Jul 2022 - Apr 2023)
- Public Relation Staff
  at Creator Club FEB Telkom University (Aug 2022 - Nov 2022)
  at FEB Awards Telkom University (Oct 2022 - Dec 2022)
- Staff Logistic
  at Insight Telkom (Nov 2021 - Feb 2022)

LinkedIn : https://www.linkedin.com/in/mrafiansyahm/

CONTENT
DATA PREPARATION

1 Introduction

2 Import Data

3 Data Exploration

4 Data Cleaning

5 Data Manipulating

Introduction

Spotify merupakan platform streaming musik terbesar di dunia dengan jutaan pengguna aktif. Tantangan utama yang dihadapi adalah bagaimana mempertahankan pelanggan agar tidak berhenti berlangganan (churn). Tahap data preparation menjadi bagian penting untuk memastikan kualitas data yang akan digunakan dalam analisis churn.

IMPORT DATA

```
#2. Import Data
df = pd.read_csv('Dataset/Spotify_Churn.csv')
df
```

user_id	gender	age	country	subscription_type	listening_time	songs_played_per_day	skip_rate	device_type	ads_listened_per_week	offline_listening	is_chu
1	Female	54	CA	Free	26	23	0.20	Desktop	31	0	
2	Other	33	DE	Family	141	62	0.34	Web	0	1	
3	Male	38	AU	Premium	199	38	0.04	Mobile	0	1	
4	Female	22	CA	Student	36	2	0.31	Mobile	0	1	
5	Other	29	US	Family	250	57	0.36	Mobile	0	1	
...	...	...	...	...	...	...	...	...	...	...	
7996	Other	44	DE	Student	237	36	0.30	Mobile	0	1	
7997	Male	34	AU	Premium	61	64	0.59	Mobile	0	1	
7998	Female	17	US	Free	81	62	0.33	Desktop	5	0	
7999	Female	34	IN	Student	245	94	0.27	Desktop	0	1	
8000	Other	45	AU	Free	210	68	0.46	Desktop	6	0	

Data Exploration

Kolom	Deskripsi Singkat	Tipe Data
user_id	ID unik tiap pengguna	int64
gender	Jenis kelamin pengguna	object
age	Usia pengguna	int64
country	Negara asal pengguna	object
subscription_type	Jenis langganan (Free, Premium, Family, Student)	object
listening_time	Total waktu mendengarkan (menit)	int64
songs_played_per_day	Jumlah lagu diputar per hari	int64
skip_rate	Persentase lagu yang dilewati	float64
device_type	Jenis perangkat yang digunakan	object
ads_listened_per_week	Jumlah iklan yang didengarkan per minggu	int64
offline_listening	Frekuensi mendengarkan offline	int64
is_churned	Status berhenti berlangganan (0 = tidak, 1 = ya)	int64

Jenis Data:

- Kategorikal: gender, country, subscription_type, device_type.
- Numerik: age, listening_time, songs_played_per_day, skip_rate, ads_listened_per_week, offline_listening.
- Target: is_churned

Data Exploration

Numeric

	user_id	age	listening_time	songs_played_per_day	skip_rate	ads_listened_per_week	offline_listening	is_churned
count	8000.00000	8000.000000	8000.000000	8000.000000	8000.000000	8000.000000	8000.000000	8000.000000
mean	4000.50000	37.662125	154.068250	50.127250	0.300127	6.943875	0.747750	0.258875
std	2309.54541	12.740359	84.015596	28.449762	0.173594	13.617953	0.434331	0.438044
min	1.00000	16.000000	10.000000	1.000000	0.000000	0.000000	0.000000	0.000000
25%	2000.75000	26.000000	81.000000	25.000000	0.150000	0.000000	0.000000	0.000000
50%	4000.50000	38.000000	154.000000	50.000000	0.300000	0.000000	1.000000	0.000000
75%	6000.25000	49.000000	227.000000	75.000000	0.450000	5.000000	1.000000	1.000000
max	8000.00000	59.000000	299.000000	99.000000	0.600000	49.000000	1.000000	1.000000

Rata-rata usia pengguna adalah 37,6 tahun, dengan rentang antara 16 hingga 59 tahun. Mayoritas pengguna berada pada kelompok usia 26–49 tahun (IQR).

Data Exploration

Kategorikal

	gender	country	subscription_type	device_type
count	8000	8000	8000	8000
unique	3	8	4	3
top	Male	AU	Premium	Desktop
freq	2691	1034	2115	2778

Dari 8000 data yang ada dalam dataset ini bisa didapatkan bahwa mayoritas pengguna spotify:

- Jenis Kelamin : Laki - laki
- Negara : Australia
- Tipe Langganan : Premium
- Tipe Perangkat : Dekstop

Data Cleaning

Duplicate

✅ Tidak ditemukan data duplikat dalam dataset.

Missing Value

✅ Tidak ada nilai yang hilang (missing value) di seluruh kolom.

Outlier

⚠️ Ditemukan 1.683 data outlier pada beberapa kolom numerik.

Data Manipulating

Feature Engineering

ubscription_type	listening_time	songs_played_per_day	skip_rate	device_type	ads_listened_per_week	offline_listening	is_churned	age_group	listening_group
Family	141	62	0.34	Web	0	1	0	Adult	Pendengar Sedang
Premium	199	38	0.04	Mobile	0	1	1	Adult	Pendengar Sedang
Student	36	2	0.31	Mobile	0	1	0	Teen	Pendengar Rendah
Family	250	57	0.36	Mobile	0	1	1	Adult	Pendengar Aktif
Premium	289	44	0.38	Desktop	0	1	0	Adult	Pendengar Aktif
...	...	...	...	...	...	...	...	...	...
Student	237	36	0.30	Mobile	0	1	1	Adult	Pendengar Aktif
Premium	61	64	0.59	Mobile	0	1	0	Adult	Pendengar Rendah
Free	81	62	0.33	Desktop	5	0	0	Teen	Pendengar Rendah
Student	245	94	0.27	Desktop	0	1	0	Adult	Pendengar Aktif
Free	210	68	0.46	Desktop	6	0	0	Adult	Pendengar Aktif

Beberapa fitur baru ditambahkan untuk memperkuat analisis churn, antara lain:

- age_group : Teen, Adult, Old.
- listening_group: Pendengar Rendah, Pendengar Sedang, Pendengar Aktif

Data Manipulating

Grouping

	age_group	songs_played_per_day
0	Teen	73557
1	Adult	176523
2	Old	67130

Beberapa fitur baru ditambahkan untuk memperkuat analisis churn, antara lain:

- age_group : Teen, Adult, Old.
- listening_group: Pendengar Rendah, Pendengar Sedang, Pendengar Aktif

Data Manipulating

Grouping

	age_group	subscription_type	songs_played_per_day
0	Teen	Family	21890
1	Teen	Free	4029
2	Teen	Premium	24630
3	Teen	Student	23008
4	Adult	Family	54945
5	Adult	Free	8051
6	Adult	Premium	58042
7	Adult	Student	55485
8	Old	Family	19296
9	Old	Free	3406
10	Old	Premium	22538
11	Old	Student	21890

Mencari jumlah songs_played_per_day berdasarkan subscription_type disetiap kelompok usia

1. Kelompok usia **Adult** mendominasi jumlah lagu yang didengarkan per hari pada semua jenis langganan.
2. Pelanggan Premium memiliki aktivitas mendengarkan lagu tertinggi di setiap kelompok **usia**, terutama pada kelompok Adult (58.042 lagu).
3. Kelompok Teen dan Old memiliki jumlah pemutaran yang lebih rendah dibandingkan Adult, namun tetap menunjukkan pola serupa: pengguna Premium dan Student lebih aktif dibandingkan Family atau Free.

Data Manipulating

Grouping & Aggregation

	age_group	mean	min	max	count
0	Teen	51.259233	1	99	1435
1	Adult	49.907549	1	99	3537
2	Old	49.910781	1	99	1345

- Teen memiliki rata-rata tertinggi (51,26 lagu/hari), menandakan remaja paling aktif mendengarkan musik.
- Adult & Old memiliki rata-rata hampir sama (49,9 lagu/hari).
- Nilai min = 1 dan max = 99
- Kelompok Adult mendominasi jumlah pengguna (3.537 data).

THANK YOU

Mini Project 1 - Data Science & Analyst
Bootcamp Offline Batch 1